

INSA Toulouse

Département GMM

4^e année Mathématiques Appliquées - Reading Seminar

Comparaison de deux méthodes de modélisation et de prédiction des séries temporelles

Auteurs

Amélie Monzie

Léo Parnotte

Jules Voegtli

Enseignante référente

Mme Cathy Maugis-Rabusseau

Abstract

Ce rapport présente une étude de modélisation et de prédiction de la température moyenne mensuelle à Toulouse sur la période 1947–2020, à partir de données issues du *National Centers for Environmental Information*. Après une analyse descriptive mettant en évidence une tendance croissante et une forte saisonnalité annuelle, deux approches de modélisation des séries temporelles sont comparées. La première repose sur une décomposition additive de la série en composantes de tendance, de saisonnalité et de bruit. La seconde approche consiste à stationnariser la série par différenciation afin d'y ajuster un modèle SARIMA. Les performances prédictives sont évaluées à court terme sur l'année 2020 et à plus long terme jusqu'à l'horizon 2035, permettant de comparer les comportements et les limites des deux méthodes.

Année universitaire 2025–2026

14 janvier 2026

Table des matières

1	Introduction	3
2	Statistiques descriptives et décomposition de la série temporelle	3
3	Modélisation de la série temporelle par estimation successive des termes du modèle	5
3.1	Estimation de la tendance	5
3.2	Estimation de la saisonnalité	7
3.3	Modélisation du bruit résiduel	7
3.4	Prédiction	13
3.4.1	Fonctionnement de la prédiction	14
3.4.2	Extrapolation de la tendance et de la saisonnalité	14
3.4.3	Construction de la série temporelle prédictive	16
4	Modélisation de la série temporelle par différenciation	18
4.1	Vérification de la non-stationnarité de $(Y_t)_{t \in T}$	19
4.2	Élimination de la saisonnalité par différenciation	19
4.3	Modélisation à partir de la série différenciée	20
4.4	Prédiction de la série temporelle à l'aide du modèle SARIMA	22
4.4.1	Principe de la prédiction SARIMA	23
4.4.2	Prédiction à court terme : validation sur l'année 2020	24
4.4.3	Prédiction à long terme	24
5	Comparaison des deux méthodes de modélisation	25
5.1	Comparaison des méthodes de modélisation et prédiction	25
5.2	Comparaison des résultats obtenus	26
6	Conclusion	27
	Annexes	29
A	Outils théoriques pour l'analyse et la modélisation des séries temporelles.	29
A.1	Caractéristiques et modélisation des séries temporelles	29
A.1.1	Processus stationnaire	29
A.1.2	Bruit Blanc faible	29
A.1.3	Opérateurs retards, polynômes en B et inversion	29
A.1.4	Modélisation des séries temporelles	31
A.2	Tests	35
A.2.1	Test de blancheur d'un processus	35
A.2.2	Test de stationnarité d'une série temporelle	36
A.3	Outils mathématiques pour l'extrapolation	37
A.3.1	B-splines	37
A.3.2	Polynôme pénalisé	37
B	Fonctions R importantes	38

1 Introduction

Dans le cadre du Reading Seminar, nous avons étudié et appliqué les concepts clés de l'estimation, de la modélisation et de la prédiction des séries temporelles. Ces dernières, parfois appelées séries chronologiques, sont des suites de valeurs numériques représentant l'évolution d'une quantité spécifique au cours du temps. Elles font l'objet d'étude dans de nombreux domaines comme la santé, l'environnement, la finance quantitative ou encore la météorologie. Ce sont des processus stochastiques, souvent indexés par le temps pour lequel les observations successives sont liées par des structures de dépendances temporelles.

L'objectif de ce rapport est de comparer deux façons différentes de modéliser les séries temporelles et de faire des prédictions. La première consiste à décomposer la série temporelle en différents termes et de les estimer successivement par un processus de moyenne mobile. La deuxième se base sur une différenciation de la série.

Pour répondre à cet objectif, nous allons nous appuyer sur un jeu de données décrivant la température moyenne mensuelle à Toulouse des années 1947 à 2020 extrait du National Centers for Environmental Information [7]. Nous réalisons dans un premier temps une analyse descriptive de cette série temporelle dans l'objectif de proposer une décomposition du modèle. Ensuite, nous allons mener les deux méthodes de modélisation (estimation successives des termes du modèle et différenciation) avant de les comparer ainsi que les prédictions réalisées.

Pour mener à bien cette étude, nous nous sommes appuyés sur des polycopiés de cours [6] et [4] ainsi que sur un jeu de données décrivant la température moyenne mensuelle à Toulouse des années 1947 à 2020. Toute notre étude a été faite grâce au logiciel R. Afin de faciliter la lecture, les concepts théoriques nécessaires à la compréhension de notre étude ont été rédigés et reportés en Annexes.

2 Statistiques descriptives et décomposition de la série temporelle

Nous allons étudier un jeu de données représentant la température moyenne mensuelle à Toulouse de l'année 1947 à l'année 2020 (de janvier 1947 à décembre 2020, soit 888 observations). Nous n'exploiterons pas les données correspondantes à l'année 2020 (on réduit donc notre série à 876 observations), mais nous nous en servons en fin de Section pour comparer la prédiction réalisée à la réalité. Nous appelons cette série temporelle $(Y_t)_{t \in T}$ où Y_t est la température moyenne du mois t et $T = \mathbb{N}$. Cette série chronologique est représentée en Figure 1.

On observe une légère tendance à l'augmentation de la moyenne des températures. On le constate notamment en observant les températures "extrêmes". Lors de la dernière décennie, les températures basses sont en moyenne supérieures à 5 degrés celsius alors que lors de la première décennie, les températures étaient en moyenne inférieures à 5 degrés celsius avec des valeurs extrêmes négatives (-2 degrés celsius notamment lors de l'année 1956).

En Figure 2 est représentée la moyenne des températures mensuelle lors des 73 années d'observation. Comme on peut facilement le supposer, on observe sur cette figure une saisonnalité de période 12 avec une évolution croissante entre les mois de janvier et d'août puis une diminution jusqu'au mois de décembre tendant vers la moyenne des températures des mois de janvier.

Finalement, on voit également sur la Figure 1 que les fluctuations ne semblent pas avoir une amplitude différente selon les années d'observation. Nous pouvons en conclure qu'il n'y a pas d'interactions ou de dépendances entre l'augmentation globale des températures et les fluctuations de températures liées aux saisons. Nous considérerons alors pour la suite de l'étude




FIGURE 1 – Série temporelle représentant l'évolution de la température moyenne mensuelle à Toulouse de janvier 1947 à décembre 2019.




FIGURE 2 – Profil saisonnier : Températures moyennes mensuelles à Toulouse de 1947 à 2019, regroupées par mois.

un modèle additif pour modéliser la série temporelle $(Y_t)_{t \in T}$ défini par :

$$\forall t \in T, Y_t = m_t + s_t + X_t \quad (1)$$

où

1. m_t est le terme de tendance : c'est une fonction déterministe traduisant les variations lentes au cours du temps de $(Y_t)_{t \in T}$
2. s_t est le terme de saisonnalité : c'est une fonction périodique de période $r = 12$ ($s_{t+r} = s_t$, $\forall t \in T$) correspondant à un phénomène périodique de période identifiée. Ce terme satisfait $\sum_{h=1}^r s_{t+h} = 0$, $\forall t \in T$.
3. $(X_t)_{t \in T}$ est un bruit aléatoire stationnaire tel que $\mathbb{E}[X_t] = 0$, $\forall t \in T$.

Maintenant que nous avons clairement établi la modélisation de la série chronologique, nous allons présenter deux façons d'estimer les valeurs de la série afin de réaliser des prédictions sur l'année 2020 que l'on a retranchée.

3 Modélisation de la série temporelle par estimation successive des termes du modèle

Dans le cas d'une série temporelle comportant une tendance et une saisonnalité, on cherche dans un premier temps à estimer ces deux termes du modèle. Nous nous en servons ensuite pour en déduire le bruit X_t et le modéliser.

3.1 Estimation de la tendance

Il existe plusieurs méthodes d'estimation de la tendance m_t , dont, l'estimation par moindres carrés, l'estimation par lissage exponentiel ou l'estimation par moyenne mobile. Nous nous focalisons ici sur l'estimation par moyenne mobile.

Une moyenne mobile est un opérateur linéaire de la forme :

$$M = \sum_{h=-v_1}^{v_2} \theta_h B^{-h}$$

avec $(v_1, v_2) \in \mathbb{N}^2$, $\theta_h \in \mathbb{R}$ pour tout $h \in \{-v_1, \dots, v_2\}$. L'opérateur retard B , appliqué à une série $(Z_t)_{t \in T}$, est défini par $BZ_t = Z_{t-1}$ et donc $B^h Z_t = Z_{t-h}$, $\forall h \in \mathbb{Z}$. Ainsi, en appliquant cet opérateur à la série temporelle $(Y_t)_{t \in T}$, on obtient

$$MY_t = \sum_{h=-v_1}^{v_2} \theta_h B^{-h} Y_t = \theta_{-v_1} Y_{t-v_1} + \dots + \theta_0 Y_t + \dots + \theta_{v_2} Y_{t+v_2}.$$

Au vu du jeu de données, et plus particulièrement de la périodicité paire ($r = 2q = 12$) paire de la série temporelle, nous allons utiliser la moyenne mobile M_{2q} qui appliquée à la série temporelle $(Y_t)_{t \in T}$ donne :

$$M_{2q} Y_t = \frac{1}{2q} \left(\sum_{h=-(q-1)}^q Y_{t+h-\frac{1}{2}} \right) = \frac{1}{4q} \left(Y_{t-q} + 2 \sum_{h=-q+1}^{q-1} Y_{t+h} + Y_{t+q} \right)$$

où

$$Y_{t-\frac{1}{2}} = \frac{1}{2}(Y_{t-1} + Y_t)$$

Cette moyenne mobile a comme caractéristiques :

— Elle est normalisée :

$$\sum_{h=-v_1}^{v_2} \theta_h = \frac{1}{4q} (1 + 2(2q - 1) + 1) = 1.$$

— Elle est symétrique : on a $v_1 = v_2 = q - 1$, deux termes extrêmes en $\pm q$, et

$$\forall h \in \{-q + 1, \dots, q - 1\}, \quad \theta_h = \theta_{-h} = \frac{1}{2q}, \text{ et } \theta_{-q} = \theta_q = \frac{1}{4q}.$$

Cette moyenne mobile est parfaitement adaptée à notre jeu de donnée de période paire puisque :

$$\begin{aligned} M_{2q}Y_t &= \frac{1}{2q} \left(\sum_{h=-(q-1)}^q Y_{t+h-\frac{1}{2}} \right) \\ &= \frac{1}{2q} \left(\sum_{h=-(q-1)}^q \frac{1}{2} (Y_{t+h-1} + Y_{t+h}) \right) \\ &= \frac{1}{4q} \left(\sum_{h=-q}^{q-1} Y_{t+h} + \sum_{h=-q+1}^q Y_{t+h} \right) \\ &= \frac{1}{4q} \left(\sum_{h=-q}^{q-1} (m_{t+h} + s_{t+h} + X_{t+h}) + \sum_{h=-q+1}^q (m_{t+h} + s_{t+h} + X_{t+h}) \right) \\ &= \frac{1}{4q} \left(\sum_{h=-q}^{q-1} m_{t+h} + \sum_{h=-q+1}^q m_{t+h} + \sum_{h=-q}^{q-1} s_{t+h} + \sum_{h=-q+1}^q s_{t+h} + \sum_{h=-q}^{q-1} X_{t+h} + \sum_{h=-q+1}^q X_{t+h} \right) \end{aligned} \quad (2)$$

Or, on a par hypothèse sur le terme de saisonnalité :

$$\sum_{h=-q}^{q-1} s_{t+h} = \sum_{h=-q+1}^q s_{t+h} = \sum_{h=1}^r s_{t-q+h} = 0. \quad (3)$$

De plus, la série des bruits résiduels étant supposée centrée, nous avons également l'approximation suivante :

$$\frac{1}{4q} \left(\sum_{h=-q}^{q-1} X_{t+h} + \sum_{h=-q+1}^q X_{t+h} \right) \approx 0. \quad (4)$$

Finalement en associant (2), (3), (4), on obtient :

$$\hat{m}_t = M_{2q}Y_t \approx \frac{1}{4q} \left(\sum_{h=-q}^{q-1} m_{t+h} + \sum_{h=-q+1}^q m_{t+h} \right).$$

Nous obtenons donc une estimation du terme de tendance, $\hat{m}_t = M_{2q}Y_t, \forall t \in T$, que nous représentons sur la Figure 3. Comme supposé précédemment, une légère augmentation de la température mensuelle à Toulouse depuis les années 60. Grâce à cette estimation de la tendance, nous allons pouvoir maintenant estimer le terme de saisonnalité.




FIGURE 3 – Représentation de l'estimation $\hat{m}_t$ de la tendance par moyenne mobile de la série temporelle.

3.2 Estimation de la saisonnalité

Afin d'estimer le terme de saisonnalité, nous allons créer une nouvelle série temporelle corrigée de la tendance estimée précédemment : $Y_t^{CT} = Y_t - \hat{m}_t$. Nous obtenons alors une série corrigée, et nous nous en servons pour obtenir notre estimation de la saisonnalité : nous calculons la température moyenne de Y_t^{CT} pour chaque mois de l'année (représentant l'écart de chaque mois à la tendance moyenne) sur l'ensemble des années de notre jeu de données. Nous réalisons donc pour chaque $k \in \{1, \dots, r\}$ une moyenne des Y_{k+jr}^{CT} avec j tel que $q < k + jr < n - q$. On a ainsi r valeurs notées w_k définies comme suit :

$$\omega_k = \frac{1}{\text{Card}\{j : q < k + jr \leq n - q\}} \sum_{\{j: q < k + jr \leq n - q\}} Y_{k+jr}^{CT}$$

Nous utilisons ces termes w_k pour estimer le terme de saisonnalité de la façon suivante :

$$\hat{s}_k = \begin{cases} \omega_k - \frac{1}{r} \sum_{i=1}^r \omega_i, & \text{pour } k \in 1, \dots, r \\ \hat{s}_{k-r}, & \text{pour } k > r. \end{cases}$$

Par cette définition, on assure l'hypothèse de départ pour le terme de saisonnalité à savoir :

$$\sum_{h=1}^r \hat{s}_{t+h} = \sum_{h=1}^r \left(w_{t+h} - \frac{1}{r} \sum_{i=1}^r w_i \right) = \sum_{h=1}^r w_{t+h} - r \times \frac{1}{r} \sum_{i=1}^r w_i = 0.$$

Comme pour l'estimation de la tendance, la saisonnalité est estimée par $\hat{s}_t, \forall t \in T$, obtenue en répétant périodiquement la moyenne des températures de chaque mois calculée précédemment sur l'ensemble des années étudiées. Nous représentons cette estimation $\hat{s}_t$ en Figure 4. Nous observons une saisonnalité forte et qui influe de manière importante sur la température moyenne. On retrouve en effet des fluctuations de $\pm 8^\circ$ en fonction de la saison.

3.3 Modélisation du bruit résiduel

En Figure 5, nous comparons la série temporelle $(Y_t)_{t \in T}$ et la série construite à partir des estimations de la tendance et de la saisonnalité $(\hat{m}_t + \hat{s}_t)_{t \in T}$. On observe des amplitudes de variations de la série temporelle plus grande que sur notre estimation, cela nous montre que




FIGURE 4 – Représentation de l'estimation $\hat{s}_t$ de la saisonnalité associée à la série temporelle sur la totalité des observations (à gauche) et pour seulement deux périodes (à droite).




FIGURE 5 – Représentation graphique de la série temporelle réelle $(Y_t)_{t \in T}$ et celle modélisée seulement par la saisonnalité et la tendance $(\hat{m}_t + \hat{s}_t)_{t \in T}$.

les deux termes m_t et s_t estimés créent une modélisation fidèle à la série temporelle réelle à quelques différences près. Ces dernières sont dues aux aléas météorologiques et sont représentées dans notre modèle par le bruit qui est, finalement, le dernier terme du modèle additif à estimer.

Naturellement, nous pouvons estimer ce bruit X_t de la façon suivante :

$$\forall t \in T, \quad \hat{X}_t = Y_t - \hat{m}_t - \hat{s}_t$$

La Figure 6 représente le bruit résiduel $\hat{X}_t$. On observe que la série temporelle est centrée autour de 0.




FIGURE 6 – Représentation graphique du bruit résiduel $(\hat{X}_t)_{t \in T}$.




FIGURE 7 – Sortie associée à la fonction R "decompose".

Pour résumer, la série temporelle étudiée est donc composée de 3 termes que nous avons estimé $\hat{m}_t, \hat{s}_t, \hat{X}_t$ manuellement. Cependant, la fonction de R `DECOMPOSE` permet de réaliser ces estimations directement et des les visualiser comme en Figure 7.

Afin de modéliser le bruit résiduel $(\hat{X}_t)_{t \in T}$, nous nous sommes appuyés sur les concepts présentés en Annexe (A). Il faut dans un premier temps vérifier que ce processus soit faiblement stationnaire. Pour cela, nous pouvons réaliser le test de Dickey-Fuller, qui teste l'hypothèse de

non stationnarité contre la stationnarité, appelé ADF [3] et présenté en Annexe(A.2.2). Dans notre cas, on rejette la non-stationnarité de la série temporelle $(X_t)_{t \in T}$ grâce au test de Dickey-Fuller car on observe une p-valeur de 0,01, validant donc que la série des bruits résiduels admet une décomposition en un modèle ARMA au risque 5%. Le test complémentaire KPSS qui teste la stationnarité contre la non-stationnarité d'un processus, également présenté en Annexe (A.2.2) valide la conclusion du test de Dickey-Fuller puisque la p-valeur associée au test est de 0,1. Les données ne rejettent donc pas l'hypothèse de stationnarité de la série temporelle au risque 5%.




FIGURE 8 – Test de blancheur des résidus bruts $(X_t)_{t \in T}$.

Le lag correspond au nombre de retards temporels considérés pour tester l'absence d'autocorrélation. Le test de Ljung-Box présenté en Annexe (A.2.1) vérifie conjointement que les autocorrélations du processus sont nulles jusqu'à un lag maximal fixé, afin d'évaluer si la série peut être assimilée à un bruit blanc. Nous voyons sur la Figure 8, qui présente les résultats du test de l'hypothèse de blancheur du bruit estimés, que ce derniers n'est pas du bruit blanc car les p-valeurs sont bien trop petites, on rejette donc l'hypothèse de blancheur. Nous devons donc modéliser $(\hat{X}_t)$ à l'aide de modèles existants, et nous pouvons utiliser les modèles ARMA présenté en Annexe (A.1.4) grâce à la stationnarité faible de nos résidus qui a été montrée précédemment.

Ce modèle est défini par

$$\Phi(B)\hat{X}_t = \Theta(B)\varepsilon_t,$$

où $(\varepsilon_t)_{t \in \mathbb{Z}}$ est un bruit blanc.

Nous cherchons, par cette modélisation, à obtenir que les résidus estimés

$$\hat{\varepsilon}_t = \hat{X}_t - \sum_{j=1}^p \hat{\varphi}_j \hat{X}_{t-j} + \varepsilon_t + \sum_{i=1}^q \hat{\theta}_i \varepsilon_{t-i}$$

soient du bruit blanc.

On caractérise la série temporelle avec les Figure 9 et Figure 10 qui représentent son autocorrélation et la son autocorrélation partielle.

En analysant les Figures 9 et 10, on observe que l'autocorrélogramme présente un dernier lag significatif au lag 6. Par ailleurs, l'autocorrélogramme partiel ne met pas en évidence de décroissance sinusoïdale caractéristique d'un processus MA pur. Ainsi, au regard des règles usuelles d'identification, nous choisissons de modéliser les bruits résiduels par un modèle ARMA(p, q), dont les ordres p et q restent à déterminer. Pour ce faire, une exploration systématique de l'ensemble des modèles ARMA(p, q) est réalisée, avec p variant de 0 à 5 et q variant de 0 à 6. Le choix du modèle est alors effectué en minimisant plusieurs critères d'information, à savoir :




FIGURE 9 – Autocorrélogramme de la série temporelle des bruits $(X_t)_{t \in T}$.




FIGURE 10 – Autocorrélogramme partiel de la série temporelle des bruits $(X_t)_{t \in T}$.

- le critère d'information d'Akaike (AIC) [1], défini par

$$\text{AIC}(p, q) = -2 \ln(L) + 2\nu(p, q),$$

- le critère d'Akaike corrigé

$$\text{AICc}(p, q) = \text{AIC} + \frac{2\nu(p, q)(\nu(p, q) + 1)}{n - \nu(p, q) - 1},$$

- le critère d'information bayésien (BIC), donné par

$$\text{BIC}(p, q) = -2 \ln(L) + \nu(p, q) \ln(n),$$

où $\nu(p, q)$ désigne le nombre de paramètres estimés, L la vraisemblance du modèle associé et n la taille de l'échantillon.

Nous avons constaté que les scores associés au modèle ARMA pour q valant 0 ou 1 étaient très mauvais, la Figure 11 représente donc les scores obtenus sans ces modèles pour plus de clarté. Nous voyons sur la Figure 11 que pour les critères AIC et AIC corrigé, le minimum est atteint avec le modèle ARMA(2,2), et qu'il est atteint avec le ARMA(2,5) pour le critère BIC. Le modèle ARMA(2,2) est le "meilleur" des modèles ARMA du point de vue de la minimisation des trois critères mais notons que les modèles ARMA(3,2) et ARMA(2,5) peuvent également être adaptés car ils présentent des valeurs très proches. Dans le but de s'assurer de la validité du modèle pour représenter nos résidus, nous réalisons un nouveau test de Ljung-Box sur le modèle ARMA(2,2) retenu ici. On cherche à confirmer que le bruit du modèle est bel et bien un bruit blanc ce qui nous permettra de reconstruire la série par la suite.

On peut voir sur la Figure 12 que le résultat du test de Ljung-Box est sans appel : on rejette l'hypothèse de blancheur du processus, le modèle n'explique pas assez bien les données. On




FIGURE 11 – Valeur des critères AIC(a), BIC(b) et AICc(c) de différents modèles $\text{ARMA}(p, q)$.




FIGURE 12 – Résultats du test Ljung box pour les $\hat{\varepsilon}_t$ du modèle $\text{ARMA}(2,2)$.




FIGURE 13 – Résultats du test Ljung-Box pour les $\hat{\varepsilon}_t$ des modèles ARMA(2,5) et ARMA(3,2).

peut voir que les p-valeurs sont bien inférieures au niveau de risque pour un nombre significatif de lags, ce qui nous permet de conclure que le modèle ARMA(2,2) n'est pas adapté. Nous allons donc tester les prochains modèles minimisant ces critères, à savoir le ARMA(3,2) et le ARMA(2,5) .

A la vue des résultats de la Figure 13 on peut voir que les deux modèles sont validés, leur p-valeurs étant bien supérieures au niveau de risque. Étant donné que le modèle ARMA(3,2) a des valeurs d'AIC et d'AIC corrigé très proches de celles du ARMA(2,2) pour une blancheur significative, et un nombre de paramètres inférieur à celui du modèle ARMA(2,5), nous choisissons ce modèle pour la modélisation du bruit. A l'aide de ce modèle nous sommes désormais capable de reconstruire notre série et de réaliser la prédiction. Nous obtenons finalement la modélisation suivante :

$$\hat{Y}_t = \hat{m}_t + \hat{s}_t + \hat{X}'_t,$$

où :

- $\hat{m}_t$ désigne la composante de tendance estimée (ici $\hat{m}_t = M_{2q}Y_t$) ;
- $\hat{s}_t$ la composante saisonnière estimée ;
- $\hat{X}'_t$ correspond à l'estimation du bruit (obtenu après soustraction des composantes additives estimées) à l'aide du modèle ARMA(3, 2).

En résumé, avec la méthode des moyennes mobiles, nous avons d'abord estimé la tendance générale de la série temporelle, ce qui nous a permis ensuite d'estimer la saisonnalité. Nous avons obtenu une tendance moyenne de l'évolution des températures de 1947 à 2019 et une estimation de la saisonnalité sur cette même fenêtre, nous avons donc soustrait les deux à notre série temporelle afin d'en isoler un bruit estimé. L'objectif est de ramener ce bruit à un bruit blanc dans l'optique de pouvoir réaliser des prédictions. Pour cela, nous avons modélisé le bruit estimé à l'aide d'un modèle ARMA dont les résidus $\hat{\varepsilon}_t$ étaient du bruit blanc. Cela nous permet maintenant de reconstruire l'intégralité de notre série et de faire nos prédictions en extrapolant la tendance et la saisonnalité sur les années à venir et en les additionnant à notre bruit prédit à l'aide du modèle.

3.4 Prédiction

Dans cette partie nous utiliserons les résultats précédents afin de réaliser de la prédiction sur notre série temporelle par la méthode de moyenne mobile. Pour cela nous allons dans un premier temps prédire les températures pour l'année 2020, année pour laquelle nous avons les données réelles et pourrons donc comparer nos résultats avec les observations. Dans un second temps, nous allons réaliser une prédiction à plus long terme pour laquelle nous n'aurons pas

de données réelles et nous pourrions évaluer l'évolution des températures dans un futur proche. Nous choisissons de faire une prédiction jusqu'à 2035.

3.4.1 Fonctionnement de la prédiction

Pour réaliser de la prédiction à l'aide des séries temporelles il est nécessaire d'extrapoler les composantes additives du modèle sur les temps voulus. Particulièrement, nous avons besoin d'extrapoler la tendance et la saisonnalité au temps futurs, ainsi que le bruit résiduel. L'extrapolation de la tendance et de la saisonnalité se fait à partir des expressions obtenues en section 3.1, et sera présentée plus en détail par la suite. Pour l'extrapolation du bruit nous nous basons sur l'expression polynomiale du modèle ARMA(3,2) que nous avons obtenue précédemment en section 3.3.

$$\Phi(B)\hat{X}_t = \Theta(B)\varepsilon_t,$$

où

$$\Phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \phi_3 B^3, \quad \Theta(B) = 1 + \theta_1 B + \theta_2 B^2,$$

et $(\varepsilon_t)_{t \in \mathbb{Z}}$ est un bruit blanc centré.

Sous l'hypothèse de causalité, c'est-à-dire si $\Phi(z) \neq 0$ pour tout $|z| \leq 1$, le polynôme $\Phi(B)$ est inversible et nous obtenons :

$$\hat{X}_t = \Phi(B)^{-1} \Theta(B) \varepsilon_t.$$

En posant

$$\Psi(B) = \Phi(B)^{-1} \Theta(B) = \sum_{j=0}^{\infty} \psi_j B^j,$$

le processus admet la représentation causale suivante :

$$\hat{X}_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j}.$$

La prévision à horizon $h \geq 1$ du bruit $\hat{X}_t$ s'écrit alors :


$$\hat{X}'_{t+h} = \sum_{j=h}^{\infty} \psi_j \varepsilon_{t+h-j}. \quad (5)$$

3.4.2 Extrapolation de la tendance et de la saisonnalité

Nous allons maintenant devoir extrapoler nos estimations de tendance et de saisonnalité sur la période de temps sur laquelle nous souhaitons réaliser notre prédiction. L'extrapolation de la saisonnalité est évidente car elle est indépendante de l'année, nous avons juste à extrapoler les valeurs sur la période de temps voulue par périodicité. Pour chaque mois k de 2020 nous prenons la valeur de $\hat{s}_t$ où t correspond au mois k .

Pour la tendance, nous allons réaliser plusieurs extrapolations : une première extrapolation constante, une seconde par B-spline et une dernière par polynôme pénalisé.

Nous commençons par faire l'extrapolation constante à partir des dernières observations, qui est la plus simple mais aussi la moins spécifique. Cela nous donne une première approximation sans doute peu fidèle pour des prévisions long terme. La Figure 14 montre cette première prévision à long terme.




(a) Extrapolation de la tendance horizon 2035.

(b) Zoom sur l'extrapolation par constante.

FIGURE 14 – Prévion de l'évolution de la tendance des températures à long terme par prolongement constant.

Dans un second temps, nous faisons une approximation de la tendance à l'aide de B-splines, des fonctions polynomiales par morceaux construites pour se rapprocher des données. Pour cela nous utilisons le package R `spline`. Ces fonction sont présentées plus en détail en Annexe (A.3.1). Grâce à cette approximation plus fidèle à la tendance générale, nous obtenons une prévision de l'évolution de la tendance présentée sur la Figure 15.



(a) Extrapolation de la tendance horizon 2035.

(b) Zoom sur l'extrapolation par splines.

FIGURE 15 – Prévion de l'évolution de la tendance à long terme par B-splines.

Cependant, la spline offre une extrapolation assez croissante et peu adaptée à la prédiction long terme par manque de stabilité, et correspond donc à un scénario de croissance maximum. Par conséquent, nous cherchons maintenant à obtenir un scénario intermédiaire qui représenterait au mieux la réalité, et nous allons utiliser pour cela la même idée qu'avec les B-spline : une approximation de la tendance par polynôme pénalisé que nous extrapolerons sur les temps futurs. Cette méthode permet de réduire la pente de l'extrapolation linéaire de la tendance tout en conservant une croissance non négligeable, à condition que les paramètres soient bien choisis. On l'obtient à l'aide du package `mgcv`. Ces fonction sont présentées plus en détail en Annexe (A.3.2) On peut voir la prévision obtenue sur la Figure 16




FIGURE 16 – Pr vision de l volution de la tendance   long terme par polyn me p nalis .

Nous pouvons voir sur la Figure 17 que les diff rentes extrapolations de la tendance forment un panel avec limite basse (constante/ETS), limite haute (Spline) et un compromis entre les deux (polyn me p nalis ). Ces diff rentes extrapolations correspondent concr tement dans ce contexte   un sc nario d volution des temp ratures moyenne   Toulouse de croissance maximum avec les splines, de croissance minimum avec le prolongement constant (not  ETS) et de croissance interm diaire avec le polyn me p nalis .




FIGURE 17 – Comparaisons des pr dictions de la tendance par les diff rentes m thodes : constante, splines, polyn me p nalis .

3.4.3 Construction de la s rie temporelle pr dictive

Afin de reconstruire la s rie temporelle sur la p riode souhait e, nous allons maintenant additionner nos extrapolations de la tendance et de la saisonnalit    notre pr diction du bruit faite   l'aide de notre mod le ARMA(3,2).

Nous pouvons voir sur la Figure 18 que la pr diction sur l'ann e 2020 avec la tendance constante est tr s proche de la pr diction avec la tendance approxim e par B-splines et polyn me p nalis . De plus, les trois pr visions sont tr s fid les   la r alit . Enfin, sur la Figure 19 la bande de




FIGURE 18 – Prédiction des températures à Toulouse en 2020.




FIGURE 19 – Intervalle de prédiction à 5% pour la prédiction par extrapolation de la tendance constante.

prédiction au niveau 95% sur l'année 2020 contient les valeurs réelles observées ce qui nous conforte dans la justesse de nos prévisions. Notons, grâce à la Figure 17, que dans l'éventualité d'une tendance croissante de l'évolution des températures, la modélisation avec approximation de la tendance par B-splines ou polynôme pénalisé sera certainement plus adaptée et fidèle que nos prévisions avec l'extrapolation de tendance constante.

C'est pourquoi nous allons réaliser maintenant les mêmes prédictions pour jusqu'à 2035. Nous pouvons voir sur la Figure 20 que pour la prédiction jusqu'en 2035 nous obtenons des résultats bien différents entre les deux méthodes, à savoir tendance constante et tendance approximée par B-splines. Comme précédemment, les résultats sont très proches pour les années suivant 2019 mais s'écartent beaucoup avec le temps. Ces résultats exhibent, comme attendu, un scénario de croissance maximale et un scénario minimal. Enfin, les prévisions par approximation avec le polynôme pénalisé permettent d'obtenir un entre deux des précédentes. Nous obtenons donc un spectre de prédictions avec une limite basse donnée par l'extrapolation constante, une limite haute donnée par l'extrapolation par splines et enfin un entre-deux obtenu par l'extrapolation par polynôme pénalisé.




FIGURE 20 – Comparaison des prédictions de 2020 à 2035 des températures mensuelles à Toulouse selon les différentes extrapolations de la tendance effectuées.

4 Modélisation de la série temporelle par différenciation

Comme nous l'avons observé dans les sections précédentes (voir Figure 1 et 2), la série temporelle étudiée $(Y_t)_{t \in T}$ présente à la fois une tendance croissante et une saisonnalité de période $r = 12$.

Or, l'ajustement d'un modèle ARMA ou ARIMA (ou plus généralement SARIMA) nécessite de travailler sur une série faiblement stationnaire, c'est-à-dire une série dont la moyenne et la variance sont constantes et dont la fonction d'autocovariance est invariable par translation temporelle et ne dépend donc que du décalage temporel entre les observations. Avec la première méthode (Section 3), nous avons explicitement estimé les composantes de tendance $(m_t)_{t \in T}$ et de saisonnalité $(s_t)_{t \in T}$, puis modélisé le bruit résiduel $(X_t)_{t \in T}$ par un modèle ARMA adapté.

Avec cette seconde approche, l'idée est complémentaire : plutôt que d'estimer séparément les

composantes additives du modèle, nous cherchons à transformer directement la série $(Y_t)_{t \in T}$ par différenciation afin d'obtenir une nouvelle série faiblement stationnaire. Le modèle SARIMA sera alors ajusté sur la série originale pour pouvoir être reconstruite ultérieurement pour les besoins de la prédiction. Pour cela, nous utilisons l'opérateur retard B introduit en Section 3.1, défini par $BY_t = Y_{t-1}$ et, plus généralement, $B^h Y_t = Y_{t-h}$ pour tout $h \in \mathbb{Z}$.

La démarche suivie dans cette section est la suivante. Nous commençons par tester formellement la non-stationnarité de la série originale $(Y_t)_{t \in T}$ (Section 4.1). Une différenciation saisonnière de période 12 est ensuite appliquée afin de supprimer la composante saisonnière annuelle (Section 4.2), conduisant à la série

$$Y_t^{(12)} = (1 - B^{12})Y_t,$$

compatible avec l'hypothèse de stationnarité faible. Un modèle SARIMA est alors identifié et estimé sur notre série $(Y_t)_{t \in T}$ (Section 4.3 et en Annexe A.1.3), avant d'être utilisé pour la prédiction après inversion de la différenciation (Section 4.4).

4.1 Vérification de la non-stationnarité de $(Y_t)_{t \in T}$

La présence simultanée d'une tendance globale croissante (Figure 1) et d'une forte saisonnalité annuelle (Figure 2) suggère que la moyenne de la série dépend du temps, ce qui est incompatible avec l'hypothèse de stationnarité faible.

Afin de confirmer ce diagnostic de manière formelle, nous appliquons à la série originale $(Y_t)_{t \in T}$ les deux tests complémentaires ADF et KPSS, dont les principes et les modalités d'interprétation ont été détaillés en Annexe A.2.2 lors de l'étude du bruit résiduel $(X_t)_{t \in T}$. Les tests sont réalisés sur la période 1947–2019 à l'aide du logiciel R (package `tseries`).

- **Test ADF** : p-valeur = 0.01. L'hypothèse de racine unitaire est rejetée au seuil de 5 %.
- **Test KPSS** : p-valeur = 0.02912. L'hypothèse de stationnarité autour d'un niveau déterministe est rejetée au seuil de 5 %.

Les conclusions des deux tests doivent être interprétées conjointement. Bien que le test ADF ne mette pas en évidence la présence d'une racine unitaire, le test KPSS rejette l'hypothèse de stationnarité autour d'un niveau déterministe. En accord avec l'analyse graphique, les résultats indiquent que la série $(Y_t)_{t \in T}$ n'est pas faiblement stationnaire.

4.2 Élimination de la saisonnalité par différenciation

Afin de rendre la série stationnaire, nous appliquons une différenciation saisonnière de période $r = 12$. Contrairement à une différenciation ordinaire qui ne traite que les variations d'un pas de temps à l'autre ($Y_t - Y_{t-1}$), la différenciation saisonnière compare les données d'un mois à celui du même mois de l'année précédente.

Nous introduisons la série différenciée saisonnièrement, notée :

$$Y_t^{(12)} = \nabla_{12} Y_t = (1 - B^{12})Y_t = Y_t - Y_{t-12}, \quad \forall t \in T$$

Cette opération présente deux propriétés essentielles :

1. Elle élimine la saisonnalité de période 12 (car $s_t - s_{t-12} = 0$).
2. Elle élimine également une tendance linéaire globale. En effet, si l'on suppose que la tendance est de la forme :

$$m_t = \alpha + \beta t,$$

alors


$$\nabla_{12} m_t = m_t - m_{t-12} = (\alpha + \beta t) - (\alpha + \beta(t-12)) = 12\beta,$$

qui est une constante. La série différenciée admet ainsi une moyenne constante, ce qui est compatible avec l'hypothèse de stationnarité faible.


Sur le plan numérique, cette différenciation saisonnière ($Y_t \in T^{(12)}$) est obtenue sous R à l'aide de la commande `DIFF(TRAIN, LAG = 12)`.

Afin de valider formellement l'hypothèse de stationnarité faible, nous appliquons à la série différenciée $(Y_t^{(12)})_{t \in T}$ les tests ADF et KPSS selon la même méthodologie que celle décrite en Section 4.1. Le test ADF rejette l'hypothèse de racine unitaire au seuil de 5 %, tandis que le test KPSS ne rejette pas l'hypothèse de stationnarité autour d'un niveau. Ces résultats confirment que la différenciation saisonnière unique ($D = 1$) est suffisante et qu'aucune différenciation ordinaire supplémentaire n'est nécessaire ($d = 0$).


La série $(Y_t^{(12)})_{t \in T}$ peut donc être considérée comme faiblement stationnaire et constitue une base valide pour l'identification et l'estimation d'un modèle SARIMA.



(a) Série différenciée saisonnièrement : $(Y_t^{(12)})_{t \in T}$.



(b) Autocorrélogramme (ACF) de $(Y_t^{(12)})_{t \in T}$.



(c) Autocorrélogramme partiel (pACF) de $(Y_t^{(12)})_{t \in T}$.

FIGURE 21 – Série différenciée saisonnièrement (a) et analyse des autocorrélations via l'ACF et la pACF (b,c).

4.3 Modélisation à partir de la série différenciée

La série différenciée saisonnièrement $(Y_t^{(12)})_{t \in T}$ étant faiblement stationnaire, nous cherchons désormais à identifier un modèle SARIMA(p, d, q)(P, D, Q) $_r$ adapté à la dynamique de la série temporelle originale $(Y_t)_{t \in T}$. Dans toute la suite, les ordres de différenciation sont fixés à $d = 0$, $D = 1$ et $r = 12$.

Le modèle SARIMA est ajusté sur la série originale (Y_t) , la différenciation saisonnière étant intégrée directement dans la structure du modèle via l'opérateur $(1 - B^{12})$. Ce cadre permet de modéliser séparément les dépendances non saisonnières et saisonnières, ce qui n'est pas possible

avec un modèle ARMA, ni avec un modèle ARIMA sans composante saisonnière. Pour une présentation théorique détaillée des modèles SARIMA, on se réfère à l'Annexe A.1.4.

Identification des ordres par la méthodologie de Box–Jenkins

Selon la méthodologie de Box–Jenkins, l'identification des ordres (p, q) et (P, Q) repose sur l'analyse conjointe des fonctions d'autocorrélation (ACF) et d'autocorrélation partielle (pACF) de la série stationnaire.

Plus précisément :

- une coupure franche de l'ACF après le lag q suggère un modèle MA(q) ;
- une coupure franche de la pACF après le lag p suggère un modèle AR(p) ;
- une décroissance progressive des deux fonctions suggère un modèle ARMA ;
- les mêmes règles s'appliquent aux lags multiples de $r = 12$ pour l'identification des composantes saisonnières P et Q .

L'analyse des ACF et pACF en Figure 21 aux lags non saisonniers ne met pas en évidence de coupure franche caractéristique d'un modèle AR ou MA pur, mais suggère une dynamique de type ARMA de faible ordre. De même, l'analyse aux lags saisonniers indique la présence d'une dépendance saisonnière résiduelle compatible avec une composante saisonnière de premier ordre. Afin de respecter un principe de parcimonie, la recherche est limitée aux ordres

$$p, q \in \{0, 1, 2\}, \quad P, Q \in \{0, 1\},$$

en fixant $d = 0$, $D = 1$ et $r = 12$.

Sélection par critères d'information et diagnostics

Pour chaque combinaison (p, q, P, Q) appartenant à cette zone de recherche, un modèle SARIMA($p, 0, q$)($P, 1, Q$) est estimé par maximum de vraisemblance. Les critères d'information AIC, AICc et BIC sont ensuite calculés, afin de comparer les modèles en tenant compte à la fois de la qualité d'ajustement et de la complexité paramétrique.

Les critères d'information seuls n'étant pas suffisants pour garantir la validité d'un modèle, un test de Ljung–Box est appliqué aux résidus de chaque modèle afin de vérifier l'absence d'autocorrélation résiduelle. Seuls les modèles pour lesquels la p-valeur du test est supérieure à 0.05 sont conservés, ce qui correspond à des résidus compatibles avec un bruit blanc.

TABLE 1 – Top 10 des modèles SARIMA validés (test de Ljung–Box, p-valeur ≥ 0.05), classés par AICc croissant.

p	q	P	Q	AIC	BIC	AICc	LB_p
2	1	0	1	3270.99	3294.798	3271.059	0.563
1	2	1	1	3271.09	3299.66	3271.187	0.671
1	2	0	1	3271.409	3295.217	3271.478	0.545
2	2	1	1	3272.518	3305.849	3272.647	0.628
2	2	0	1	3272.607	3301.177	3272.704	0.527
1	1	1	1	3292.319	3316.126	3292.388	0.483
2	1	1	1	3292.734	3321.303	3292.831	0.239
1	0	1	1	3293.869	3312.915	3293.915	0.286
2	0	1	1	3294.391	3318.198	3294.46	0.323
1	1	0	1	3294.437	3313.483	3294.483	0.231

La Table 1 présente les dix modèles satisfaisant ce critère diagnostique et minimisant le critère AICc. On observe que les modèles les mieux classés comportent systématiquement une composante saisonnière MA d'ordre 1 ($Q = 1$), tandis que la présence d'un terme AR saisonnier ($P = 1$) n'apporte pas d'amélioration significative au regard des critères d'information.

Parmi les modèles admissibles, le modèle SARIMA(2, 0, 1)(0, 1, 1)₁₂ présente la plus faible valeur de l'AICc, ainsi que la plus faible valeur du BIC, tout en satisfaisant au test de Ljung–Box. Il constitue donc le meilleur compromis entre qualité d'ajustement, parcimonie et validité diagnostique.

Écriture explicite du modèle retenu

À l'issue de la procédure d'identification, de sélection par critères d'information et de validation diagnostique des résidus, le modèle retenu est SARIMA(2, 0, 1)(0, 1, 1)₁₂. Le modèle est ajusté sur la série originale $(Y_t)_{t \in T}$, la différenciation saisonnière étant intégrée dans la structure du modèle via l'opérateur $(1 - B^{12})$. L'estimation par maximum de vraisemblance conduit aux coefficients suivants :

$$\hat{\phi}_1 = 1.1235, \quad \hat{\phi}_2 = -0.1241, \quad \hat{\theta}_1 = -0.9781, \quad \hat{\Theta}_1 = -0.9817.$$

Ces coefficients sont obtenus à l'aide de la commande suivante sous R :

```
fit_sarima <- Arima(train,
                    order = c(2,0,1),
                    seasonal = c(0,1,1),
                    include.constant = FALSE)
coef(fit_sarima)
```

L'écriture polynomiale du modèle estimé est donc donnée par

$$(1 - 1.1235 B + 0.1241 B^2)(1 - B^{12})Y_t = (1 - 0.9781 B)(1 - 0.9817 B^{12})\varepsilon_t,$$

où $(\varepsilon_t)_{t \in \mathbb{Z}}$ désigne un bruit blanc centré de variance constante.

Cette écriture fixe entièrement le modèle utilisé dans la section suivante pour la prévision de la série temporelle.

4.4 Prédiction de la série temporelle à l'aide du modèle SARIMA

Le modèle SARIMA(2, 0, 1)(0, 1, 1)₁₂ ayant été validé à l'issue de la section précédente, nous l'utilisons désormais pour réaliser des prévisions de la série temporelle des températures mensuelles à Toulouse à partir de 2020 et jusqu'en 2035.

Contrairement à la méthode développée en Section 3, où la prédiction reposait sur l'extrapolation explicite de la tendance et de la saisonnalité, l'approche par différenciation intègre directement ces composantes dans la structure probabiliste du modèle SARIMA. La prédiction est ainsi effectuée de manière globale, sans nécessiter d'estimation séparée des composantes additives.

Nous représentons en Figure 22 la série temporelle observée ainsi que la série ajustée par le modèle SAMIRA.




FIGURE 22 – Comparaison entre la série observée des températures mensuelles à Toulouse et la série ajustée obtenue à l’aide du modèle $\text{SARIMA}(2, 0, 1)(0, 1, 1)_{12}$ sur la période 1947–2019.

On observe que la série ajustée reproduit fidèlement la dynamique de la série observée. Les écarts ponctuels correspondent à des fluctuations aléatoires non expliquées par le modèle.




FIGURE 23 – Résidus $(\hat{\varepsilon}_t)_{t \in T}$ du modèle $\text{SARIMA}(2, 0, 1)(0, 1, 1)_{12}$ ajusté sur la période 1947–2019.

La Figure 23 représente l’évolution temporelle des résidus du modèle $\text{SARIMA}(2, 0, 1)(0, 1, 1)_{12}$ ajusté sur la période 1947–2019. Les résidus apparaissent globalement centrés autour de zéro, sans structure temporelle apparente, ce qui confirme la bonne qualité de l’ajustement et la capacité du modèle à capturer l’essentiel de la dépendance temporelle de la série.

4.4.1 Principe de la prédiction SARIMA

Un modèle $\text{SARIMA}(p, d, q)(P, D, Q)_r$ permet de réaliser des prévisions en travaillant sur une série rendue stationnaire par différenciation. Dans notre cas ($d = 0$, $D = 1$, $r = 12$), le modèle est ajusté sur la série originale $(Y_t)_{t \in T}$, la différenciation saisonnière étant intégrée directement dans la structure du modèle via l’opérateur $(1 - B^{12})$. On impose ainsi que la série transformée

$$\nabla_{12} Y_t = Y_t - Y_{t-12}$$

admette une dynamique de type ARMA.

La prédiction consiste d’abord à prévoir cette série différenciée implicite à l’aide du modèle SARIMA, en utilisant les valeurs passées observées. Les valeurs futures sont obtenues de manière itérative à partir de la structure du modèle. La série originale est ensuite reconstruite en ajoutant, à chaque instant prédit, la valeur située un an plus tôt. Cette reconstruction est effectuée automatiquement par la fonction `FORECAST()` du logiciel R.

4.4.2 Prédiction à court terme : validation sur l'année 2020

Afin d'évaluer la qualité prédictive du modèle, nous réalisons dans un premier temps une prévision sur l'année 2020, pour laquelle les observations réelles sont disponibles. La Figure 24 présente les prévisions ponctuelles ainsi que l'intervalle de prédiction à 95 %, obtenus à partir du modèle SARIMA.




FIGURE 24 – Prédiction des températures mensuelles à Toulouse pour l'année 2020 obtenue à l'aide du modèle $\text{SARIMA}(2, 0, 1)(0, 1, 1)_{12}$. La bande bleue correspond à l'intervalle de prédiction à 95 %, tandis que la courbe rouge représente les observations réelles.

On observe que les valeurs relevées en 2020 sont contenues dans l'intervalle de prédiction à 95 %, ce qui indique une bonne capacité du modèle à capturer la dynamique temporelle de la série à court terme. Le léger décrochage observé au début de la période de prévision s'explique par la reconstruction de la série originale à partir d'un modèle ajusté sur la série différenciée saisonnièrement, la prévision reposant sur les valeurs observées à l'horizon $t - 12$ ce qui peut induire un décalage initial sans remettre en cause la dynamique prédictive du modèle.

4.4.3 Prédiction à long terme

Nous étendons maintenant la prévision à un horizon plus lointain, jusqu'à l'année 2035. Les prévisions à long terme issues d'un modèle SARIMA tendent vers une dynamique moyenne dictée par la structure du modèle et par la différenciation saisonnière, d'où la redondance visuelle de cycles sur la Figure 25 La méthode par différenciation fournit donc des prévisions plus conservatrices, basées sur la dynamique historique de la série.




FIGURE 25 – Prédiction des températures mensuelles à Toulouse à l’horizon 2035.

5 Comparaison des deux méthodes de modélisation

Dans cette partie, nous allons tâcher de comparer nos prédictions dans le but d’apporter une conclusion quant à l’évolution des températures à Toulouse dans un futur proche. Pour cela, nous allons comparer uniquement la prédiction à long terme car les variations sur la seule année 2020 ne sont pas significatives.


5.1 Comparaison des méthodes de modélisation et prédiction

Afin de départager les prédictions de ces modèles, nous allons nous intéresser à leurs caractéristiques. Par défaut, lors de la prédiction par méthode additive, nous devons extrapoler la tendance sur les temps futurs. Pour réaliser cette extrapolation de la tendance d’une série temporelle le logiciel `R` ne fait pas réellement de prédiction mais se contente de faire un raccord constant des dernières valeurs obtenues. Cette méthode naïve est plutôt adaptée à des prévisions court terme mais perd de son intérêt sur le long terme. Néanmoins, ce modèle offre la possibilité de réaliser d’autres extrapolations de la tendance avec des méthodes mathématiques diverses de part la connaissance explicite de la tendance estimée. Les choix des méthodes d’extrapolation peuvent se faire grâce à la connaissance des réalités physiques modélisées par la tendance, comme ici, qui nous a conduit à utiliser une approximation par splines et par polynôme pénalisé. Ces extrapolations perdent en fidélité sur les temps passés car elles correspondent à une approximation de notre moyenne mobile. Cependant, elles gagnent dans le futur avec une croissance nette et linéaire, que l’on sait correspondre à la réalité actuelle de l’évolution des températures, bien que la stabilité puisse être moindre.

Au contraire, lors de la prédiction par différenciation, de part l’utilisation de la fonction `ARIMA()`, la tendance est supprimée (cf 4.4). Par conséquent, lors de l’appel de la fonction `FORECAST()`, l’extrapolation de la tendance qui se fait à l’aide du modèle statistique `ETS` est aussi constante car cette dernière a été supprimée. On retrouve donc un résultat similaire à celui décrit précédemment, bien que celui-ci soit réellement une prédiction à l’aide d’un modèle statistique et non un prolongement naïf. Cette méthode ne laisse cependant pas la même liberté sur l’extrapolation de la tendance.

5.2 Comparaison des résultats obtenus

Comme expliqué précédemment, la prédiction de la méthode additive par prolongement constant est naïve et ne s'appuie sur aucun test statistique. Dans un premier temps nous comparons les prévisions par extrapolation de la moyenne mobile en constante avec celle obtenue par différenciation. Nous obtenons, avec la méthode par différenciation, un résultat similaire à la prédiction par prolongement constant de la méthode additive, nous comparons donc ce résultat à la prédiction par splines qui est la plus extrême.



(a) Comparaison entre différenciation et constante. (b) Comparaisons entre différenciation et splines

FIGURE 26 – Comparaison entre les prédictions obtenues par méthode additive et par différenciation.

Nous pouvons voir sur la Figure 26 que la prédiction obtenue par différenciation de la série d'origine est légèrement en dessous de la prédiction par extrapolation constante de la tendance et présente la même tendance constante. Elle correspond donc à un bon scénario limite basse de l'évolution des températures. La prédiction par extrapolation de la tendance sous forme de spline se trouve donc naturellement bien au dessus des deux, avec la même croissance linéaire qui présente l'avantage d'explorer un scénario limite haute. Nous gardons la prévision par différenciation plutôt que celle par extrapolation de la tendance constante car elles explorent toutes deux un scénario futur similaire mais la prédiction par différenciation a l'avantage d'être issue d'un modèle statistique. Néanmoins, nous estimons que les deux autres prédictions réalisées dans la méthode additive présentent l'avantage d'exhiber une tendance croissante. Ils correspondent donc à une approximation fidèle tout en explorant deux scénarios complémentaires à celui représenté par la prédiction par différenciation, à savoir un scénario limite haute et un scénario intermédiaire. L'ensemble de ces résultats forment donc un outil adapté à la prédiction de l'évolution de températures, comme le montre la Figure 27.




FIGURE 27 – Comparaison des prédictions de l'évolution de la température à Toulouse à horizon 2035 par les différentes méthodes : différenciation, splines, polynôme pénalisé.

En effet, la Figure 27 présente l'ensemble des prévisions à horizon 2035 et permet de saisir l'ensemble des évolutions possibles selon les différents scénarios. nous pouvons voir que les différents scénarios ne diffèrent que par leur pente moyenne, ce qui est du aux différents choix d'extrapolation effectués. Ces scénarios permettent de comprendre la nature physique des différentes évolution possibles, avec notamment : un premier cas de croissance maximum de la température à Toulouse d'environ $1,5^{\circ}\text{C}$ en 15 ans, avec la prédiction par spline, un second cas de croissance minimale de la température à Toulouse qui serait constante, obtenue par différenciation et un dernier cas de croissance intermédiaire de la température à Toulouse d'environ $0,5^{\circ}\text{C}$ en 15 ans, obtenue avec le polynôme pénalisé.

6 Conclusion

Pour conclure, cette étude sur les températures moyennes à Toulouse de l'année 1947 à 2019, nous a permis de mettre en oeuvre deux méthodes classiques de modélisation des séries temporelles.

La première méthode, basée sur la décomposition additive de la série en tendance, saisonnalité et bruit, nous a permis d'avoir une vision globale de l'évolution des températures à Toulouse. Ainsi, après estimation et modélisation de ces trois termes, il est possible d'explorer plusieurs scénarios de prévision à plus ou moins long terme grâce à des choix d'extrapolation de la tendance.

À l'inverse, la deuxième méthode basée sur une différenciation saisonnière se distingue par sa simplicité. Elle permet une prédiction directe à partir du modèle choisi pour modéliser la série temporelle, particulièrement efficace à court terme. En revanche, la suppression explicite de la tendance limite sa capacité à produire des scénarios de croissance réalistes à long terme.

Ces deux méthodes permettent de réaliser des prédictions semblables à court terme, notamment pour l'année 2020. Cependant, la méthode additive permet d'explorer différents scénarios à long terme et produit des prévisions plus cohérentes que la deuxième méthode qui sont souvent sous-estimées.

Finalement, ces deux méthodes doivent être considérées comme complémentaire. En effet,

la méthode par différenciation constitue un outil direct, rapide et souvent utilisé pour la prédiction statistique alors que la la méthode par estimation des termes du modèles permet une compréhension plus fine des caractéristiques physiques de la série.

Le choix de la méthode dépend ainsi des objectifs de l'étude, de l'horizon de prévision considéré et du niveau d'interprétabilité recherchée.

Annexes

A Outils théoriques pour l'analyse et la modélisation des séries temporelles.

A.1 Caractéristiques et modélisation des séries temporelles

A.1.1 Processus stationnaire

Afin de modéliser le bruit résiduel $(X_t)_{t \in T}$, il convient dans un premier temps de vérifier que ce dernier est un processus faiblement stationnaire, c'est-à-dire que sa fonction moyenne est constante, $E[X_t] = \mu_X$, et que la covariance entre deux observations ne dépend que du décalage temporel qui les sépare. Autrement dit, la fonction de covariance est invariante par translation temporelle et s'écrit

$$\text{Cov}(X_t, X_s) = \text{Cov}(X_0, X_{s-t}) = f(s-t).$$

Après avoir validé la stationnarité de la série temporelle, nous pouvons le caractériser avec deux fonctions, celle d'autocovariance γ_X et celle d'autocorrélation ρ_X définie par :

$$\gamma_X : \mathbb{Z} \rightarrow \mathbb{R}, \quad h \mapsto \gamma_X(h) = \text{Cov}(X_h, X_0) = \text{Cov}(X_{t+h}, X_t). \quad (6)$$

$$\rho_X : \mathbb{Z} \rightarrow [-1, 1], \quad h \mapsto \rho_X(h) = \frac{\gamma_X(h)}{\gamma_X(0)} = \text{Corr}(X_{t+h}, X_t) = \frac{\text{Cov}(X_{t+h}, X_t)}{\sqrt{\text{Var}(X_t) \text{Var}(X_{t+h})}}. \quad (7)$$

Cette dernière fonction et sa représentation graphique, l'autocorrélogramme, est centrale dans la sélection du modèle pour modéliser le processus stationnaire X_t que nous verrons plus tard.

Une autre fonction essentielle pour choisir le modèle à adopter pour modéliser la série des bruits est la fonction d'autocorrélation partielle. Cette dernière correspond à la corrélation directe entre la variable X_{t+h} et X_t après avoir éliminé l'effet des points intermédiaires.

A.1.2 Bruit Blanc faible

Définition 1 (Bruit blanc faible). *On appelle bruit blanc faible toute suite de variables aléatoires $(\varepsilon_t)_{t \in T}$ vérifiant les propriétés suivantes :*

— *la suite est centrée et de variance constante, c'est-à-dire*

$$\mathbb{E}[\varepsilon_t] = 0 \quad \text{et} \quad \text{Var}(\varepsilon_t) = \sigma^2, \quad \forall t \in T;$$

— *les variables sont non corrélées, autrement dit*

$$\text{Cov}(\varepsilon_t, \varepsilon_s) = 0, \quad \forall t \neq s.$$

On note alors $(\varepsilon_t)_{t \in T} \sim \text{WN}(0, \sigma^2)$.

Par la suite, nous utiliserons le terme bruit blanc pour plus de simplicité.

A.1.3 Opérateurs retards, polynômes en B et inversion

Opérateurs de retard Les séries temporelles étant des objets mathématiques dépendants du temps $t \in T$, nous pouvons les représenter récursivement à l'aide de deux opérateurs : L'opérateur d'avance et l'opérateur de retard.

Définition 2. L'opérateur avance F sur une série temporelle $(Y_t)_{t \in T}$ est défini par :

$$FY_t = Y_{t+1}, \quad \forall t \in T.$$

On note :

$$F^h Y_t = Y_{t+h}, \quad \forall t \in T \text{ et } \forall h \in \mathbb{N}^*,$$

A l'inverse, on définit l'opérateur retard B d'une série temporelle $(Y_t)_{t \in T}$ par :

$$BY_t = Y_{t-1}, \quad \forall t \in T.$$

On note :

$$B^h Y_t = Y_{t-h}, \quad \forall t \in T \text{ et } \forall h \in \mathbb{N}^*.$$

et

$$B^{-h} = F^h, \quad \text{pour tout } h.$$

Cette représentation permet notamment de définir les méthodes d'estimation de moyenne mobile, et surtout introduit la notion de polynôme en B essentielle à la méthode de modélisation par différenciation.

Définition 3. Une moyenne mobile est un opérateur linéaire de la forme

$$M = \sum_{h=-m_1}^{m_2} \theta_h B^{-h},$$

où $(m_1, m_2) \in \mathbb{N} \times \mathbb{N}$ et $\theta_h \in \mathbb{R}$ pour tout h , représentant le poids accordé à chaque instant h .

Polynômes en B La notion de polynômes en B est essentielle à la méthode de modélisation des séries temporelles, que ce soit par décomposition ou par différenciation.

Définition 4. Un Polynôme en B est défini par :

$$\left(\sum_{i \in T} a_i B^i \right) X_t = \sum_{i \in T} a_i X_{t-i}$$

On appelle Série en B l'opérateur

$$P(B) = \sum_{i \in \mathbb{Z}} a_i B^i$$

qui transforme le processus stationnaire $(X_t)_{t \in T}$ en un autre processus stationnaire $(Y_t)_{t \in T}$, défini par :

$$Y_t = P(B)X_t = \left(\sum_{i \in \mathbb{Z}} a_i B^i \right) X_t = \sum_{i \in \mathbb{Z}} a_i X_{t-i}, \quad \forall t \in \mathbb{Z}$$

Notons que les séries en B sont stables par combinaisons linéaires et composition, et se manipulent donc comme les séries réelles.

Inversion de polynôme/Recherche de racine Par la suite, nous supposons que nous avons une représentation polynomiale explicite pour notre série temporelle, que l'on notera

$$\Phi(B)$$

telle que

$$Y_t = \phi(B)X_t = \left(\sum_{i \in \mathbb{Z}} a_i B^i \right) X_t = \sum_{i \in \mathbb{Z}} a_i X_{t-i}, \quad \forall t \in \mathbb{Z} \quad (8)$$

Il est donc maintenant intéressant de se demander si notre polynôme est inversible, ce qui nous permet d'obtenir l'expression de $(X_t)_{t \in T}$ en fonction de $(Y_t)_{t \in T}$. De plus, il est nécessaire de s'assurer de l'unicité et de la stationnarité du processus $(X_t)_{t \in T}$. L'intérêt de la recherche des racines de notre polynôme est double :

D'une part, elle permet de s'assurer de l'inversibilité et donc de reconstruire le modèle.

Proposition L'opérateur $\Phi(B)$ est inversible si et seulement si toutes les racines de Φ ont un module différent de 1. Dans ce cas,

$$\Phi(B)^{-1} = \sum_{j=-\infty}^{+\infty} \psi_j B^j = \Psi(B),$$

avec

$$\sum_{j=-\infty}^{+\infty} |\psi_j| < +\infty.$$

On a $\psi_j = 0$ pour tout $j < 0$ si et seulement si toutes les racines de Φ sont de module strictement plus grand que 1 (on dit aussi toutes les racines à l'extérieur du disque unité).

Et on obtient l'expression de l'unique processus X_t solution de l'équation (8) avec

$$X_t = \Phi(B)^{-1} Y_t$$

D'autre part, elle permet de tester la non stationnarité du processus associé.

Proposition Si $\Phi(B)$ possède une racine unitaire, c'est-à-dire une racine λ telle que $|\lambda| = 1$, alors le processus X_t vérifiant l'équation (8) n'est pas stationnaire.

A.1.4 Modélisation des séries temporelles

Un processus centré peut admettre différentes décompositions en fonction de ses caractéristiques (ACF et pACF). Différents modèles permettent d'approcher n'importe quel processus stationnaire centré, à savoir

Modèle AR Le terme AR est issu de AutoRegressive, et correspond aux modèles vérifiant :

$$X_t - \varphi_1 X_{t-1} - \varphi_2 X_{t-2} - \cdots - \varphi_p X_{t-p} = \varepsilon_t,$$

où $(\varepsilon_t)_{t \in \mathbb{Z}} \sim \text{WN}(0, \sigma^2)$ et $(\varphi_1, \dots, \varphi_p) \in \mathbb{R}^p$ avec $\varphi_p \neq 0$.

On peut écrire ces modèles en utilisant les polynômes en B introduits précédemment : Un processus $\text{AR}(p)$ vérifie l'équation :

$$\Phi(B)X_t = \varepsilon_t, \quad \forall t \in \mathbb{Z},$$

avec le polynôme en B défini par :

$$\Phi(B) = I - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p.$$

Cette représentation est dite **canonique** si le bruit blanc $(\varepsilon_t)_{t \in \mathbb{Z}}$ est tel que :

$$\varepsilon_t \perp \mathcal{H}_{-\infty}^{t-1}(X), \quad \text{pour tout } t \in \mathbb{Z},$$

où $\mathcal{H}_{-\infty}^{t-1}(X)$ désigne l'histoire passée de la série jusqu'à $t - 1$.

Autrement dit, ces modèles sont utilisés pour les processus qui dépendent du passé dans le présent. Les termes de la série temporelle à un instant t peuvent donc être représentés comme une combinaison linéaire des termes précédents et d'un bruit blanc centré.

Pour identifier les processus éligibles à une représentation sous forme de modèle AR on regarde l'ACF et la pACF du processus :

Proposition 1. *Si la fonction d'autocorrélation (ACF) décroît exponentiellement ou présente une décroissance sinusoïdale amortie vers 0, et si la fonction d'autocorrélation partielle (pACF) est nulle à partir d'un rang p , alors le processus peut être représenté par un modèle autorégressif d'ordre p , noté AR(p).*

Il ne reste par la suite qu'à valider le modèle avec divers tests statistiques. Pour cela, on peut se baser sur les propriétés des polynômes en B :

Proposition 2.

- Il existe une infinité de processus $(X_t)_{t \in \mathbb{Z}}$ satisfaisant cette équation.
- Si toutes les racines de $\Phi(B)$ sont de module différent de 1, alors il existe une **unique solution stationnaire** $(X_t)_{t \in \mathbb{Z}}$, qui s'écrit comme un filtrage linéaire du bruit blanc :

$$X_t = \Psi(B)\varepsilon_t = \sum_{i \in \mathbb{Z}} \psi_i \varepsilon_{t-i}, \quad \forall t \in \mathbb{Z}.$$

- Si toutes les racines de $\Phi(B)$ sont à l'extérieur du disque unité (i.e. de module strictement supérieur à 1), alors la représentation moyenne mobile du processus ne dépend que des valeurs passées du bruit blanc :

$$X_t = \Psi(B)\varepsilon_t = \sum_{i \in \mathbb{N}} \psi_i \varepsilon_{t-i}, \quad \forall t \in \mathbb{Z}.$$

Modèle MA Le terme MA se réfère quant à lui à Moving Average, et correspond aux modèles vérifiant :

$$X_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q},$$

où $(\varepsilon_t)_{t \in \mathbb{Z}} \sim \text{WN}(0, \sigma^2)$ et $(\theta_1, \dots, \theta_q) \in \mathbb{R}^q$ avec $\theta_q \neq 0$.

Comme pour les modèles AR, on peut utiliser la représentation polynomiale suivante pour notre modèle : Un processus MA(q) peut s'écrire sous la forme :

$$X_t = \Theta(B)\varepsilon_t, \quad \forall t \in \mathbb{Z},$$

avec le polynôme en B défini par :

$$\Theta(B) = I + \theta_1 B + \theta_2 B^2 + \dots + \theta_q B^q.$$

Cette représentation est dite **canonique** si les racines du polynôme $\Theta(z)$ sont toutes à l'extérieur du disque unité.

Autrement dit, ces modèles correspondent à des processus stationnaires qui peuvent être représentés comme une combinaison linéaire des perturbations précédentes indépendantes entre elles. Ces perturbations sont des bruits blancs centrés.

Pour identifier les processus éligibles à une représentation sous forme de modèle MA on regarde l'ACF et la PACF du processus :

Proposition 3. *Si la fonction d'autocorrélation partielle (pACF) décroît exponentiellement ou présente une décroissance sinusoïdale amortie vers 0, et si la fonction d'autocorrélation (ACF) est nulle à partir d'un rang q , alors le processus peut être représenté par un modèle de moyenne mobile d'ordre q , noté MA(q).*

Comme précédemment, les propriétés des polynômes en B nous donne la proposition suivante :

Proposition 4.

- Le processus $(X_t)_{t \in \mathbb{Z}}$ admet plusieurs représentations MA(q) différentes. Si $\tilde{\Theta}(B)$ est un polynôme ayant pour racines celles de $\Theta(B)$ ou leurs inverses, alors :

$$X_t = \tilde{\Theta}(B)\eta_t, \quad \forall t \in \mathbb{Z},$$

avec $(\eta_t)_{t \in \mathbb{Z}}$ un bruit blanc.

- Une seule représentation est dite **canonique** : celle pour laquelle toutes les racines de $\Theta(B)$ sont à l'extérieur du disque unité.
- Un processus MA est **stationnaire** quelle que soit sa représentation, car il s'agit d'un filtrage linéaire d'un bruit blanc.
- Un processus MA est toujours **centré**, c'est-à-dire que $\mathbb{E}[X_t] = 0$ pour tout t .

Enfin, dans la plupart des cas, les deux modèles présentés précédemment ne suffisent pas seuls à représenter correctement un processus stationnaire, ce qui motive l'introduction de modèles plus généraux.

Modèle ARMA Le terme ARMA correspond quant à lui à une combinaison linéaire des deux modèles présentés précédemment :

Définition 5. *Un modèle ARMA(p, q) est défini par :*

$$X_t = \sum_{j=1}^p \varphi_j X_{t-j} + \varepsilon_t + \sum_{i=1}^q \theta_i \varepsilon_{t-i}$$

avec

- $(\varepsilon_t)_{t \in \mathbb{Z}} \sim WN(0, \sigma^2)$
- $(\varphi_1, \dots, \varphi_p) \in \mathbb{R}^p, \quad \varphi_p \neq 0$
- $(\theta_1, \dots, \theta_q) \in \mathbb{R}^q, \quad \theta_q \neq 0$

On obtient une réécriture sous forme polynomiale : Un processus ARMA(p, q) est défini par l'équation :

$$\Phi(B)X_t = \Theta(B)\varepsilon_t, \quad \forall t \in \mathbb{Z},$$

où les polynômes en l'opérateur de retard B sont donnés par :

$$\Phi(B) = I - \varphi_1 B - \varphi_2 B^2 - \cdots - \varphi_p B^p,$$

$$\Theta(B) = I + \theta_1 B + \theta_2 B^2 + \cdots + \theta_q B^q,$$

et $(\varepsilon_t)_{t \in \mathbb{Z}}$ est un bruit blanc.

La stationnarité du processus dépend des racines du polynôme autorégressif $\Phi(B)$:

- Si toutes les racines de $\Phi(B)$ sont **strictement en dehors du disque unité** ($|\lambda| > 1$), le processus est stationnaire.
- Si $\Phi(B)$ possède une **racine unitaire** ($|\lambda| = 1$), alors le processus n'est pas stationnaire.

L'inversibilité du processus dépend des racines du polynôme de moyenne mobile $\Theta(B)$:

- Si toutes les racines de $\Theta(B)$ sont **strictement en dehors du disque unité**, le processus est inversible.
- La présence d'une racine unitaire dans $\Theta(B)$ empêche l'inversibilité et rend le modèle non identifiable.

Modèle SARIMA Les modèles précédents supposent que la série est *stationnaire*. Or, dans de nombreuses applications (dont notre série de températures mensuelles), la présence d'une tendance et d'une saisonnalité impose une étape de *stationnarisation* avant modélisation. Les modèles SARIMA (*Seasonal AutoRegressive Integrated Moving Average*) généralisent les modèles ARIMA en incorporant une composante saisonnière de période r .

Définition 6. Soit $r \in \mathbb{N}^*$ la période saisonnière (dans ce rapport, $r = 12$). Un modèle SARIMA(p, d, q)(P, D, Q) $_r$ est défini par l'équation polynomiale :

$$\Phi(B) \Phi_r(B^r) (1 - B)^d (1 - B^r)^D Y_t = \Theta(B) \Theta_r(B^r) \varepsilon_t, \quad \forall t \in \mathbb{Z},$$

où $(\varepsilon_t)_{t \in \mathbb{Z}} \sim \text{WN}(0, \sigma^2)$, et où les polynômes en B sont donnés par :

$$\Phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi_p B^p, \quad \Theta(B) = 1 + \theta_1 B + \theta_2 B^2 + \cdots + \theta_q B^q,$$

$$\Phi_r(B^r) = 1 - \phi_1 B^r - \phi_2 B^{2r} - \cdots - \phi_P B^{Pr}, \quad \Theta_r(B^r) = 1 + \theta_1 B^r + \theta_2 B^{2r} + \cdots + \theta_Q B^{Qr}.$$

Les opérateurs de différenciation $(1 - B)^d$ et $(1 - B^r)^D$ permettent de supprimer respectivement une non-stationnarité *non saisonnière* (ordre d) et une non-stationnarité *saisonnière* (ordre D).

Cas de la différenciation saisonnière (période 12).

Dans notre étude, la stationnarisation est obtenue par une différenciation saisonnière d'ordre $D = 1$ et de période $r = 12$, c'est-à-dire :

$$Y_t^{(12)} = (1 - B^{12})Y_t = Y_t - Y_{t-12}.$$

Le modèle SARIMA est alors ajusté sur la série stationnarisée $Y_t^{(12)}$, puis la série initiale (Y_t) est reconstruite a posteriori lors de la phase de prévision.

Identification des ordres par Box-Jenkins.

L'identification des ordres (p, q) et (P, Q) repose sur l'analyse conjointe de l'ACF et de la pACF de la série stationnaire. En particulier :

- des pics marqués aux lags multiples de r dans l'ACF (resp. pACF) suggèrent la présence d'une composante MA saisonnière (resp. AR saisonnière) ;
- une coupure franche de l'ACF (resp. pACF) après un certain rang suggère un modèle MA (resp. AR), tandis qu'une décroissance amortie suggère une dynamique ARMA.

Validation du modèle.

Une fois le modèle estimé, il doit être validé par diagnostic des résidus : ceux-ci doivent être compatibles avec un bruit blanc (absence d'autocorrélation résiduelle, variance constante). Cela peut notamment être vérifié via l'ACF des résidus et un test de Ljung-Box.

A.2 Tests

A.2.1 Test de blancheur d'un processus

L'objectif du test de Ljung-Box [5] est de vérifier la blancheur d'une série temporelle que l'on note $(B_t)_{t \in \mathbb{Z}}$. On suppose que l'on observe $B_1, \dots, B_n$. Les hypothèses du test sont les suivantes :

$$\begin{cases} H_0 : (B_t)_{t \in \mathbb{Z}} \text{ est un bruit blanc,} \\ H_1 : (B_t)_{t \in \mathbb{Z}} \text{ n'est pas un bruit blanc.} \end{cases}$$

La statistique de test de Ljung-Box est définie par :

$$Q_k = n(n+2) \times \sum_{h=1}^k \frac{\hat{\rho}_{B,n}(h)^2}{n-h} \quad (9)$$

avec $\hat{\rho}_{B,n}(h)$, l'estimateur de la fonction d'autocorrélation en h que l'on définit par :

$$\hat{\rho}_{X,n}(h) = \frac{\sum_{t=1}^{n-|h|} (X_t - \bar{X}_n) (X_{t+|h|} - \bar{X}_n)}{\sum_{t=1}^n (X_t - \bar{X}_n)^2}.$$

Sous H_0 ,

$$Q_k \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} \chi^2(k).$$

Sous H_1 , Q_k a tendance à être élevée ainsi nous posons la zone de rejet suivante :

$$R_\alpha^{(k)} = \{Q_k > q_{1-\alpha,k}\} \quad (10)$$

Finalement, on a la p-valeur suivante :

$$\hat{\alpha} = P_{H_0}(Q_k > Q_k^{obs}) \xrightarrow[n \rightarrow \infty]{} 1 - F_{\chi^2(k)}(Q_k^{obs}) \quad (11)$$

Dans tout notre rapport, nous réalisons des tests de taille $\alpha = 5\%$. Lorsque nous réalisons un test sur une série temporelle, nous le représentons par une figure comme la Figure 13 par exemple. Nous observons alors la p-valeur pour chaque k fixé. L'objectif étant d'observer un graphique dans lequel pour chaque k , la p-valeur est supérieure à 5% (et donc ne pas rejeter l'hypothèse de blancheur du processus).

Pour réaliser ces tests, nous avons utilisé la fonction `R BOX.LJUNG.TEST`.

A.2.2 Test de stationnarité d'une série temporelle

Dickey-Fuller L'objectif du test de Dickey Fuller [3] est de vérifier la stationnarité ou non d'une série temporelle $(B_t)_{t \in \mathbb{Z}}$. Il se base sur le postulat qu'un processus est non-stationnaire si il possède une racine unitaire. De plus, on modélise une série temporelle à l'aide d'un modèle auto-regressif de degré 1 de la façon suivante :

$$B_t = \alpha + \gamma B_{t-1} + \varepsilon_t \quad (12)$$

avec $(\alpha, \gamma) \in \mathbb{R}^2$ et $(\varepsilon_t)_{t \in \mathbb{Z}} \sim \text{WN}(0, \sigma^2)$

L'objectif du test de Dickey-Fuller n'est pas de modéliser explicitement la série temporelle par un modèle autorégressif d'ordre 1, mais d'étudier si son comportement asymptotique peut être assimilé à celui d'un processus AR(1). Le test vise ainsi à déterminer si la série se comporte comme une marche aléatoire (présence d'une racine unitaire) ou si, au contraire, elle est stationnaire et ne diverge pas dans le temps.

Si une série temporelle $(B_t)_{t \in \mathbb{Z}}$ possède une racine unitaire si $|\gamma| = 1$ alors elle n'est pas stationnaire. Elle l'est si $|\gamma| < 1$, puisque :

$$B_t = \alpha + \gamma B_{t-1} + \varepsilon_t \Leftrightarrow (1 - \gamma B)B_t = \alpha + \varepsilon \quad (13)$$

d'où,

$$\Phi(z) = 1 - \gamma z = 0 \Leftrightarrow z = \frac{1}{\gamma} \quad (14)$$

et finalement,

$$|z| = \left| \frac{1}{\gamma} \right| > 1 \Leftrightarrow |\gamma| < 1 \quad (15)$$

Les hypothèses du test sont les suivantes :

$$\begin{cases} H_0 : (B_t)_{t \in \mathbb{Z}} \text{ n'est pas stationnaire, ie } |\gamma| = 1 \\ H_1 : (B_t)_{t \in \mathbb{Z}} \text{ est stationnaire, ie } |\gamma| < 1. \end{cases}$$

La première étape consiste à reparamétriser les hypothèses et le modèle. Nous allons nous servir des équations suivantes :

$$\Delta B_t = B_t - B_{t-1} = \alpha + (\gamma - 1)B_{t-1} + \varepsilon_t = \alpha + \pi B_{t-1} + \varepsilon_t \quad (16)$$

Finalement les hypothèses sont les suivantes :

$$\begin{cases} H_0 : (B_t)_{t \in \mathbb{Z}} \text{ n'est pas stationnaire, ie } \pi = 0 \\ H_1 : (B_t)_{t \in \mathbb{Z}} \text{ est stationnaire, ie } \pi < 0. \end{cases}$$

Nous posons alors la statistique de test suivante :

$T = \frac{\hat{\pi}}{se(\hat{\pi})}$ où $\hat{\pi}$ est l'estimateur des moindres carrés de π .

Finalement, on compare la statistique de test observée aux seuils tabulés de Dickey et Fuller et on obtient la zone de rejet suivante :

$$R_\alpha = \{T < T_\alpha\} \quad (17)$$

avec T_α le quantile que l'on détermine grâce à la Figure 28. Dans notre cas, nous utiliserons le cas 2 et une taille inf. Les autres cas correspondent à une autre modélisation par un processus autoregressif (cas 1 : $B_t = \nu B_{t-1} + \varepsilon_t$ et cas 3 : $B_t = \omega + \beta \times t + \delta B_{t-1} + \varepsilon_t$). Ainsi, comme nous réalisons des tests de taille $\alpha = 5\%$, $T_{DF} = -2.86$.

Pour réaliser ces tests, nous avons utilisé la fonction R `ADF.TEST`.

TABLE B.6
Critical Values for the Phillips-Perron Z_t Test and for the Dickey-Fuller Test
Based on Estimated OLS t Statistic

Sample size T	Probability that $(\hat{\rho} - 1)/\hat{\sigma}_\varepsilon$ is less than entry							
	0.01	0.025	0.05	0.10	0.90	0.95	0.975	0.99
<i>Case 1</i>								
25	-2.66	-2.26	-1.95	-1.60	0.92	1.33	1.70	2.16
50	-2.62	-2.25	-1.95	-1.61	0.91	1.31	1.66	2.08
100	-2.60	-2.24	-1.95	-1.61	0.90	1.29	1.64	2.03
250	-2.58	-2.23	-1.95	-1.62	0.89	1.29	1.63	2.01
500	-2.58	-2.23	-1.95	-1.62	0.89	1.28	1.62	2.00
∞	-2.58	-2.23	-1.95	-1.62	0.89	1.28	1.62	2.00
<i>Case 2</i>								
25	-3.75	-3.33	-3.00	-2.63	-0.37	0.00	0.34	0.72
50	-3.58	-3.22	-2.93	-2.60	-0.40	-0.03	0.29	0.66
100	-3.51	-3.17	-2.89	-2.58	-0.42	-0.05	0.26	0.63
250	-3.46	-3.14	-2.88	-2.57	-0.42	-0.06	0.24	0.62
500	-3.44	-3.13	-2.87	-2.57	-0.43	-0.07	0.24	0.61
∞	-3.43	-3.12	-2.86	-2.57	-0.44	-0.07	0.23	0.60
<i>Case 4</i>								
25	-4.38	-3.95	-3.60	-3.24	-1.14	-0.80	-0.50	-0.15
50	-4.15	-3.80	-3.50	-3.18	-1.19	-0.87	-0.58	-0.24
100	-4.04	-3.73	-3.45	-3.15	-1.22	-0.90	-0.62	-0.28
250	-3.99	-3.69	-3.43	-3.13	-1.23	-0.92	-0.64	-0.31
500	-3.98	-3.68	-3.42	-3.13	-1.24	-0.93	-0.65	-0.32
∞	-3.96	-3.66	-3.41	-3.12	-1.25	-0.94	-0.66	-0.33

The probability shown at the head of the column is the area in the left-hand tail.

Source: Wayne A. Fuller, *Introduction to Statistical Time Series*, Wiley, New York, 1976, p. 373.

FIGURE 28 – Table de Dickey et Fuller pour le test de stationnarité d’une série temporelle.

Kwiatkowski-Phillips-Schmidt-Shin (KPSS) Le test de KPSS [3] est également utilisé en complément du test de Dickey Fuller. Il a pour objectif de tester la stationnarité d’une série temporelle avec les hypothèses suivantes :

$$\begin{cases} H_0 : (B_t)_{t \in \mathbb{Z}} \text{ est stationnaire} \\ H_1 : (B_t)_{t \in \mathbb{Z}} \text{ n'est pas stationnaire.} \end{cases}$$

Le test repose sur la décomposition de la série temporelle en une composante déterministe (constante ou tendance) et un résidu. Il consiste à analyser le comportement des sommes partielles des résidus afin de détecter la présence d’une racine unitaire. Comme pour le test de Dickey-Fuller, la statistique de test ne suit pas une loi classique sous l’hypothèse nulle, et les quantiles sont tabulées.

Pour réaliser ces tests, nous avons utilisé la fonction R `KPSS.TEST`.

A.3 Outils mathématiques pour l’extrapolation

Pour présenter ces notions nous nous basons notamment sur le cours [2].

A.3.1 B-splines

Une B-spline est une fonction spline définie par :

- un ensemble de **nœuds** qui segmentent l’axe du temps,
- un **degré**, souvent 3
- des **coefficients** qui pondèrent chaque fonction de base.

La spline finale est une combinaison linéaire des fonctions de base :

$$S(t) = \sum_{i=1}^k \beta_i B_i(t)$$

où $B_i(t)$ sont les fonctions de base et β_i leurs coefficients.

A.3.2 Polynôme pénalisé

Un polynôme pénalisé $P_d(t)$ cherche à minimiser la fonction de coût suivante :

$$\sum_t (y_t - P_d(t))^2 + \lambda \int \left(P_d^{(m)}(t)\right)^2 dt$$

où :

- $P_d(t)$ est un polynôme de degré d ,
- $P_d^{(m)}(t)$ est la m -ième dérivée du polynôme,
- $\lambda \geq 0$ est le paramètre de pénalité qui contrôle le compromis entre ajustement aux données et lissage.

B Fonctions R importantes

Cette annexe présente les principaux packages R utilisés dans le projet, ainsi que les fonctions essentielles pour l'analyse, la modélisation et la validation des modèles de séries temporelles.

Package stats (base R)

- `arma()` : ajuste un modèle ARIMA ou SARIMA sur une série temporelle.
- `decompose()` : réalise une décomposition classique additive ou multiplicative d'une série temporelle en tendance, saisonnalité et résidu.

Package forecast

- `forecast()` : produit des prévisions à horizon donné à partir d'un modèle ajusté, incluant les prévisions ponctuelles et les intervalles de prédiction.
- `ggAcf()` : calcule et représente la fonction d'autocorrélation (ACF).
- `ggPacf()` : calcule et représente la fonction d'autocorrélation partielle (PACF).

Package tseries

- `adf.test()` : implémente le test de Dickey-Fuller augmenté pour détecter la présence d'une racine unitaire (non-stationnarité).
- `kpss.test()` : implémente le test KPSS de stationnarité, complémentaire au test ADF.

Package LSTS

- `Box.Ljung.Test()` : implémentation du test de Ljung-Box permettant d'évaluer l'hypothèse de bruit blanc, utilisée pour la validation des résidus du modèle.

Références

- [1] H. AKAIKE. “Information Theory and an Extension of the Maximum Likelihood Principle”. In : *Proceedings of the Second International Symposium on Information Theory*. Sous la dir. de B. N. PETROV et F. CSÁKI. 1973.
- [2] CCSBQ. *Modèles additifs généralisés en R*. 2023. URL : <https://r.qcbs.ca/workshop08/book-fr/index.html>.
- [3] D. DICKEY et Wayne FULLER. “Distribution of the Estimators for Autoregressive Time Series With a Unit Root”. In : *JASA. Journal of the American Statistical Association* 74 (juin 1979). DOI : 10.2307/2286348.
- [4] ENSAI. *Polycopié — Séries temporelles (Polyseriestemp)*. 2019. URL : <https://ensai.fr/wp-content/uploads/2019/06/Polyseriestemp.pdf>.
- [5] Greta M. LJUNG et George E. P. BOX. “On a Measure of Lack of Fit in Time Series Models”. In : *Biometrika* (1978).
- [6] Cathy MAUGIS-RABUSSEAU. *TimesSeries4MA*. 2023. URL : <https://cmaugis.github.io/TimesSeries4MA/>.
- [7] NATIONAL CENTERS FOR ENVIRONMENTAL INFORMATION. *Climate Data Online*. 2025. URL : <https://www.ncei.noaa.gov/> (visité le 07/02/2025).